

Detección Automática de Fracturas Óseas en Radiografías Mediante Modelos de Visión por Computadora Basados en Deep Learning

Lucia T. Capon Paul
CEIA – FIUBA
Buenos Aires, Argentina

Cesar Orellana
CEIA – FIUBA
Buenos Aires, Argentina

Leandro Britez
CEIA – FIUBA
Buenos Aires, Argentina

Abstract—La detección automatizada de fracturas óseas en imágenes radiográficas representa un desafío clínico de alto impacto. En este trabajo se presenta el desarrollo de un prototipo basado en modelos de detección de objetos preentrenados para la identificación y localización de fracturas en radiografías. Se comparan dos arquitecturas: YOLOv11, representativa del paradigma anchor-free de una etapa, y RT-DETR, un detector basado en transformers de tiempo real. Los modelos son ajustados (*fine-tuned*) sobre el dataset público *Bone Fracture Detection* de Roboflow Universe. La evaluación se realiza en términos de mAP@0.5, mAP@0.5:0.95, F1-score y latencia de inferencia. [COMPLETAR CON RESULTADOS].

Index Terms—detección de objetos, fracturas óseas, YOLOv11, RT-DETR, deep learning, visión por computadora, radiografías.

I. INTRODUCCIÓN

La interpretación de imágenes radiográficas es una tarea clínica fundamental en el diagnóstico de traumatismos y patologías óseas. La identificación visual de fracturas requiere experiencia especializada y puede verse afectada por factores como la carga de trabajo y la fatiga del profesional [?].

Los sistemas de visión por computadora basados en *deep learning* han demostrado capacidad para asistir en tareas de detección y localización de patologías en imágenes médicas [?]. En particular, los modelos de detección de objetos permiten no solo determinar la presencia de una lesión, sino también localizar su posición mediante cuadros delimitadores (*bounding boxes*).

El objetivo de este trabajo es desarrollar y evaluar un prototipo funcional capaz de detectar automáticamente fracturas óseas en radiografías, comparando el desempeño de dos arquitecturas modernas: YOLOv11 [?] y RT-DETR [?].

II. METODOLOGÍA, DISEÑO Y DESARROLLO

A. Dataset

Se utilizó el dataset *Bone Fracture Detection* disponible públicamente en Roboflow Universe [?]. El dataset contiene imágenes de radiografías con anotaciones en formato YOLO (*bounding boxes*). Las particiones utilizadas son:

TABLE I
DISTRIBUCIÓN DEL DATASET POR SPLIT

Split	Imágenes	Anotaciones
Train	–	–
Valid	–	–
Test	–	–

B. Preprocesamiento y Data Augmentation

Todas las imágenes fueron redimensionadas a 640×640 píxeles. Se aplicaron las siguientes técnicas de *data augmentation* durante el entrenamiento: variaciones de matiz y saturación (HSV), flip horizontal, traslación aleatoria y escalado. Para RT-DETR se desactivó el *mosaic augmentation* por ser incompatible con la arquitectura *transformer*.

C. Arquitecturas

YOLOv11 [?]: detector *anchor-free* de una sola etapa. Se utilizó la variante `yolo11m.pt` preentrenada en COCO.

RT-DETR [?]: detector basado en transformers diseñado para inferencia en tiempo real. Se utilizó la variante `rtdetr-l.pt` preentrenada en COCO.

D. Entrenamiento

Ambos modelos fueron ajustados durante 100 épocas con optimizador *AdamW*. Los hiperparámetros completos se documentan en el repositorio de GitHub en los archivos `configs/yolov11.yaml` y `configs/model2.yaml`.

III. RESULTADOS EXPERIMENTALES Y ANÁLISIS

TABLE II
COMPARACIÓN DE MÉTRICAS EN EL CONJUNTO DE TEST

Modelo	mAP@0.5	mAP@0.5:0.95	F1	Latencia (ms)
YOLOv11	–	–	–	–
RT-DETR	–	–	–	–

IV. CONCLUSIONES

- 1) ...
- 2) ...
- 3) ...
- 4) ...
- 5) ...

REFERENCES

- [1] Author, "Title," Journal, vol. X, pp. Y-Z, year.
- [2] Author, "Title," in Proc. Conference, year, pp. X-Y.
- [3] Ultralytics, "YOLO11: State-of-the-Art Object Detection," 2024. [Online]. Available: <https://github.com/ultralytics/ultralytics>
- [4] L. Leng et al., "DETRs Beat YOLOs on Real-time Object Detection," arXiv:2304.08069, 2023.
- [5] Roboflow Universe, "Bone Fracture Detection Dataset," 2024. [Online]. Available: <https://universe.roboflow.com/veda/bone-fracture-detection-daoon>