

Detección Automática de Fracturas Óseas en Radiografías

Mediante YOLOv11 y RT-DETR con Preprocesamiento Fotométrico

Lucia T. Capon Paul
CEIA – FIUBA
Buenos Aires, Argentina

César Andrés Orellana
CEIA – FIUBA
Buenos Aires, Argentina

Leandro Britez
CEIA – FIUBA
Buenos Aires, Argentina

Abstract—La detección automatizada de fracturas óseas en imágenes radiográficas representa un desafío clínico de alto impacto, donde la precisión y la velocidad de diagnóstico son críticas. En este trabajo se presenta un prototipo basado en modelos de detección de objetos preentrenados para la identificación y localización de fracturas en radiografías de múltiples regiones anatómicas. Se comparan dos arquitecturas modernas: YOLOv11 [?], representativa del paradigma *anchor-free* de una etapa, y RT-DETR [?], un detector basado en transformers de tiempo real. Ambos modelos son ajustados (*fine-tuned*) sobre el dataset público *Bone Fracture Detection* de Roboflow Universe [?], que contiene 4.148 radiografías distribuidas en seis clases anatómicas. Previamente al entrenamiento se aplica un pipeline de preprocesamiento fotométrico que combina normalización robusta por percentiles, ecualización adaptativa de histograma con límite de contraste (CLAHE) y enmascaramiento no nítido (*unsharp masking*), siguiendo la metodología propuesta por Srinivasu *et al.* [?]. La evaluación se realiza en términos de mAP@0.5, mAP@0.5:0.95, F1-score y latencia de inferencia.

Index Terms—detección de objetos, fracturas óseas, YOLOv11, RT-DETR, CLAHE, *unsharp masking*, *deep learning*, visión por computadora, radiografías.

I. INTRODUCCIÓN

La interpretación de imágenes radiográficas es una tarea clínica fundamental en el diagnóstico de traumatismos musculoesqueléticos. El cuerpo humano posee 206 huesos cuyas fracturas pueden presentarse como interrupciones transversales, oblicuas, espirales o conminutas, muchas veces con escaso contraste respecto del tejido circundante [?]. La identificación visual requiere experiencia especializada y puede verse comprometida por factores como la carga de trabajo, la fatiga del profesional o variaciones instrumentales en la adquisición de la imagen.

Los sistemas de visión por computadora basados en *deep learning* han demostrado capacidad para asistir en tareas de detección y localización de patologías en imágenes médicas [?]. En particular, los detectores de objetos permiten no solo determinar la presencia de una lesión sino también localizar su posición mediante cuadros delimitadores (*bounding boxes*), lo que complementa el criterio clínico sin pretender reemplazarlo.

Un antecedente directo es el trabajo de Srinivasu *et al.* [?], que evaluó YOLOv10 para detectar fracturas multiclase en radiografías con el mismo dataset de Roboflow Universe. Los autores combinaron CLAHE y *unsharp masking* como preprocesamiento fotométrico y reportaron una mejora de mAP@0.5 de 0,948 a 0,961 respecto de imágenes sin procesar. Motivados por este antecedente, el presente trabajo compara YOLOv11 y RT-DETR bajo un protocolo de partición fija y evalúa el efecto del mismo pipeline de preprocesamiento sobre la capacidad de localización y clasificación de fracturas.

El objetivo de este trabajo es desarrollar y evaluar un prototipo funcional capaz de detectar automáticamente fracturas óseas en radiografías, comparando el desempeño de YOLOv11 [?] y RT-DETR [?] en términos de métricas de detección y latencia de inferencia. Los aportes principales son: (i) la aplicación y justificación de un pipeline de preprocesamiento conservador adaptado a la variabilidad del dataset, (ii) la comparación directa de un detector de una etapa con un detector basado en transformers bajo el mismo protocolo experimental, y (iii) el análisis por clase para identificar limitaciones del dataset.

II. METODOLOGÍA, DISEÑO Y DESARROLLO

A. Dataset

Se utilizó el dataset *Bone Fracture Detection* disponible públicamente en Roboflow Universe (versión 1, licencia CC BY 4.0) [?]. El dataset contiene radiografías de múltiples regiones anatómicas con anotaciones en formato YOLO (*bounding boxes*). La Tabla ?? resume la distribución de imágenes y anotaciones por partición.

Las imágenes sin caja delimitadora se tratan como negativos verdaderos y permiten al modelo aprender cuándo no debe activarse. No se hallaron duplicados exactos entre particiones (verificado mediante hash SHA-256), lo que descarta fuga de datos (*data leakage*). La auditoría de anotaciones no detectó clases fuera de rango ni geometrías inválidas.

El dataset original declara siete clases. Durante el análisis exploratorio se comprobó que la clase *humerus* presentaba únicamente tres anotaciones en entrenamiento y ninguna en

TABLE I
DISTRIBUCIÓN DEL DATASET POR PARTICIÓN

Partición	Imágenes	Con bbox	Anotaciones
Train	3.631	1.804	2.088
Valid	348	173	204
Test	169	83	96
Total	4.148	2.060	2.388

validación ni test, constituyendo una anomalía residual sin representatividad estadística. Esas anotaciones fueron unificadas programáticamente con la clase `humerus fracture` por coherencia anatómica, resultando en seis clases efectivas. La distribución de anotaciones en entrenamiento se muestra en la Tabla ??.

TABLE II
DISTRIBUCIÓN DE ANOTACIONES POR CLASE EN ENTRENAMIENTO

Clase	Anotaciones	%
fingers positive	531	25,43
shoulder fracture	360	17,24
elbow positive	339	16,24
forearm fracture	316	15,13
humerus fracture	314	15,04
wrist positive	228	10,92
Total	2.088	100

El dataset presenta un desbalance leve a moderado: la clase mayoritaria (`fingers positive`) más que duplica a la minoritaria (`wrist positive`). Esto se tiene en cuenta al analizar las métricas por clase, en particular para determinar si el modelo logra detectar correctamente las categorías con menor representación. El análisis exploratorio reveló además que las imágenes tienen resoluciones heterogéneas (ancho medio: 412 px, alto medio: 486 px), niveles de brillo variados (media: 54/255) y que aproximadamente la mitad de cada partición carece de fractura anotada, lo que refleja la prevalencia clínica real.

B. Preprocesamiento

Las imágenes presentan variaciones de contraste y brillo atribuibles a diferencias en el equipo, la posición del paciente y la exportación del archivo. Para mejorar la visibilidad local de las estructuras óseas antes del entrenamiento, se aplicó un pipeline de preprocesamiento determinista, igual sobre las tres particiones. No se modificó la geometría de las imágenes ni las anotaciones.

El pipeline se evaluó comparando visualmente dos configuraciones. Se eligió la configuración P2 (realce conservador) sobre P1 (realce más agresivo) porque P1 amplificaba el granulado y los marcadores de los equipos, introduciendo artefactos potencialmente confusos para el detector.

1) *Normalización robusta por percentiles*: Se escalan las intensidades al rango $[0, 255]$ descartando los valores extremos

(percentiles 1 y 99). Esto evita que píxeles anómalos muy oscuros o muy claros dominen el histograma global, produciendo imágenes con rangos dinámicos comparables entre radiografías de distintos equipos.

2) *CLAHE*: La ecualización adaptativa de histograma con límite de contraste (CLAHE) divide la imagen en regiones de 8×8 píxeles y ecualiza el histograma local con un límite de amplificación de 1,5. A diferencia de la ecualización global, el límite de contraste evita la amplificación excesiva del ruido en regiones homogéneas, mejorando la visibilidad de estructuras óseas de bajo contraste sin distorsionar las zonas uniformes.

3) *Enmascaramiento no nítido (unsharp masking)*: El *unsharp masking* refuerza las componentes de alta frecuencia (bordes) restando a la imagen una versión suavizada de sí misma:

$$O(x, y) = I(x, y) + \gamma[I(x, y) - I_b(x, y)], \quad (1)$$

donde $I(x, y)$ es la intensidad original, $I_b(x, y)$ la imagen suavizada con $\sigma = 1,0$ y $\gamma = 0,25$ controla la magnitud del realce. Un valor conservador de γ resalta transiciones sutiles sin introducir bordes artificiales. Los parámetros completos de la configuración P2 se resumen en la Tabla ??.

TABLE III
PARÁMETROS DEL PIPELINE DE PREPROCESAMIENTO (CONFIGURACIÓN P2)

Parámetro	Valor
Normalización percentil bajo / alto	1 / 99
CLAHE clip limit	1,5
CLAHE tile grid size	8×8
Unsharp σ	1,0
Unsharp γ	0,25
Calidad JPEG exportación	95

C. Arquitecturas

YOLOv11 [?]: detector *anchor-free* de una sola etapa de la familia Ultralytics. Se utilizó la variante `yolo11m.pt` (medium, $\approx 20M$ parámetros) preentrenada en COCO. YOLOv11 introduce mejoras en el bloque C3k2, atención SPPF con cabezal desacoplado y una cadena de regresión de cuadros más eficiente que sus predecesores.

RT-DETR-L [?]: detector basado en transformers diseñado para inferencia en tiempo real. Se utilizó la variante `rt detr-l.pt` (large, $\approx 32M$ parámetros) preentrenada en COCO. RT-DETR emplea un *backbone* ResNet con un *encoder* híbrido CNN-transformer y un *decoder* de atención cruzada que elimina la supresión de no máximos (NMS) del post-procesamiento.

La elección de estas dos arquitecturas responde a la necesidad de comparar el paradigma de detección de una etapa con regresión directa (YOLOv11) frente al paradigma basado en atención global (RT-DETR), analizando el compromiso entre precisión de localización y latencia de inferencia.

D. Configuración del Entrenamiento

Ambos modelos se configuraron para un máximo de 100 épocas con tamaño de entrada 640×640 píxeles. La Tabla ?? detalla los hiperparámetros de cada modelo. El ajuste fino (*fine-tuning*) transfiere los pesos preentrenados en COCO y reemplaza la cabeza de clasificación para adaptarla a las seis clases del dataset.

TABLE IV
HIPERPARÁMETROS DE ENTRENAMIENTO POR MODELO

Parámetro	YOLOv11	RT-DETR-L
Pesos base	yolo11m.pt	rt detr-l.pt
Épocas (máx.)	100	100
Early stopping	–	patience = 20
Optimizador	auto (SGD)	AdamW
Batch size	16	8
lr_0	0,01	0,0001
lr_f	0,001	0,00001
Weight decay	0,0005	0,0001
Warmup epochs	3	2
Mosaic aug.	1,0	0,0
Mixup aug.	0,1	0,0
Flip horizontal	0,5	0,5
Flip vertical	0,0	0,0
Conf. umbral inf.	0,25	0,25
IoU NMS	0,70	0,70

Para RT-DETR se desactivaron *mosaic* y *mixup* por incompatibilidad con la arquitectura basada en atención. Se empleó una tasa de aprendizaje significativamente menor (0,0001 vs. 0,01) dado que los *decoders* de tipo DETR son sensibles a tasas elevadas durante el ajuste fino; el optimizador se fijó explícitamente en AdamW, dado que el modo automático de selección de Ultralytics (`optimizer=auto`) ignora la tasa de aprendizaje especificada por el usuario y determina una propia. Asimismo, se detectó que el entrenamiento inicial de RT-DETR divergía (*loss* de clasificación con valores NaN) al utilizar precisión mixta (AMP); este comportamiento es un problema conocido de los *decoders* basados en atención de tipo DETR bajo `fp16`, por lo que se deshabilitó AMP para dicho modelo. Se incorporó además un criterio de *early stopping* (`patience=20`) para evitar cómputo innecesario una vez alcanzada la meseta de convergencia; con este criterio, RT-DETR-L detuvo su entrenamiento en la época 58, correspondiendo el mejor checkpoint a la época 38. El entrenamiento se realizó en Google Colab con GPU NVIDIA A100 (80GB), implementado con la librería Ultralytics. Los archivos de configuración completos están disponibles en el repositorio (`configs/yolov11.yaml` y `configs/model2.yaml`).

III. RESULTADOS EXPERIMENTALES Y ANÁLISIS

Esta sección reporta los resultados obtenidos para RT-DETR-L sobre el conjunto de test (169 imágenes, 96 anotaciones), evaluado con el mejor *checkpoint* (época 38) bajo el protocolo descrito en la Sección II. La evaluación de YOLOv11m sobre el mismo conjunto de test se encuentra en

curso al momento de este informe; la Tabla ?? se completará con dichos valores en la versión final.

TABLE V
COMPARACIÓN DE MÉTRICAS EN EL CONJUNTO DE TEST

Modelo	mAP@0.5	mAP@0.5:0.95	F1	Lat. (ms)
YOLOv11m	–	–	–	–
RT-DETR-L	0,2475	0,0802	0,2854	41,68

RT-DETR-L alcanzó una latencia mediana de 41,68 ms por imagen (P95: 46,38 ms; ≈ 24 FPS) sobre una GPU NVIDIA A100, sin *batching* (*batch size* = 1), lo que resulta compatible con un escenario de asistencia diagnóstica no crítico en tiempo real, aunque debe evaluarse en hardware de despliegue equivalente al clínico antes de extraer conclusiones sobre viabilidad en producción.

A. Análisis por Clase

Dado que el mAP global promedia clases con soporte muy dispar (desde 6 hasta 43 instancias en test), se analiza el desempeño por clase en la Tabla ??.

TABLE VI
MÉTRICAS POR CLASE DE RT-DETR-L EN EL CONJUNTO DE TEST

Clase	P	R	AP@0.5
forearm fracture	0,720	0,553	0,512
humerus fracture	0,387	0,467	0,375
shoulder fracture	0,327	0,235	0,238
wrist positive	0,093	0,167	0,176
fingers positive	0,395	0,122	0,140
elbow positive	0,000	0,000	0,043
Media	0,320	0,257	0,248

El modelo alcanza su mejor desempeño en *forearm fracture* ($AP@0.5 = 0,512$) y *humerus fracture* ($AP@0.5 = 0,375$), clases con anotaciones de mayor tamaño relativo y contorno óseo bien definido. En el extremo opuesto, *elbow positive* obtiene Precision y Recall nulos al umbral de confianza de inferencia (0,25): el modelo no logró aprender un patrón discriminativo para esta clase, pese a contar con la tercera mayor cantidad de anotaciones en entrenamiento (339), lo que sugiere que el problema no es puramente de escasez de datos sino de variabilidad morfológica o solapamiento visual con clases vecinas (a confirmar con la matriz de confusión). *wrist positive*, pese a ser la clase con menor soporte en test (6 instancias), no es la de peor desempeño, lo que indica que el tamaño de muestra por sí solo no explica el patrón de errores observado.

B. Dinámica de Entrenamiento

RT-DETR-L mostró una convergencia rápida durante las primeras 30 a 38 épocas, entrando luego en una meseta sin mejoras sostenidas en el *fitness* de validación, lo que activó el criterio de *early stopping* en la época 58. Este comportamiento

es consistente con la sensibilidad reportada de los *decoders* DETR a la capacidad del dataset: con 3.631 imágenes de entrenamiento, el mecanismo de *matching* húngaro dispone de señal limitada para refinar las consultas (*queries*) de las clases con peor desempeño.

IV. CONCLUSIONES

- 1) ...
- 2) ...
- 3) ...
- 4) ...
- 5) ...

REFERENCES

- [1] P. N. Srinivasu, G. L. A. Kumari, S. C. Narahari, S. Ahmed y A. Alhumam, "Exploring the impact of hyperparameter and data augmentation in YOLO V10 for accurate bone fracture detection from X-ray images," *Scientific Reports*, vol. 15, art. 9828, 2025. doi: 10.1038/s41598-025-93505-4.
- [2] Z. Su, X. Adam, Y. Zhao, H. Fan, Z. Dong y L. Zhao, "Skeletal fracture detection with deep learning: A comprehensive review," *Diagnostics*, vol. 13, n.º 20, art. 3245, 2023. doi: 10.3390/diagnostics13203245.
- [3] Ultralytics, "YOLO11: State-of-the-Art Object Detection," 2024. [En línea]. Disponible: <https://github.com/ultralytics/ultralytics>
- [4] Y. Zhao, W. Lv, S. Xu, J. Wei, G. Wang, Q. Dang, Y. Liu y J. Chen, "DETRs Beat YOLOs on Real-time Object Detection," *arXiv preprint arXiv:2304.08069*, 2023.
- [5] Roboflow Universe, "Bone Fracture Detection Dataset," 2024. [En línea]. Disponible: <https://universe.roboflow.com/veda/bone-fracture-detection-daoon>
- [6] R. Y. Ju y W. Cai, "Fracture detection in pediatric wrist trauma X-ray images using YOLOv8 algorithm," *Scientific Reports*, vol. 13, art. 20077, 2023. doi: 10.1038/s41598-023-47460-7.